

Espacialização da evapotranspiração de referência (ET₀) diária: reprodução metodológica de Baratto et al. (2022) e contribuição com krigagem, RFRK e Wilcoxon

Antonio Albuquerque de Oliveira Neto¹, Gabriel Antônio de Oliveira Rocha¹

¹CESAR School - Recife, PE - Brasil

{aaon, gaor}@cesar.school

Abstract. This work reproduces the methodology, not the exact values, of Baratto et al. (2022) for daily reference evapotranspiration (ET₀) spatialization. Using 12 automatic INMET stations in Espírito Santo (2023), we compare IDW, ADW, Random Forest, ordinary kriging and Random Forest Regression Kriging through daily spatial leave-one-out validation. The pipeline includes data cleaning, Hargreaves-Samani ET₀ estimation, model comparison, Wilcoxon testing, variable-importance analysis, MLflow tracking, Streamlit and Docker. Results show near-equivalent numerical performance; RF leads by a small margin, while RFRK improves visual smoothness.

Resumo. Este trabalho reproduz a metodologia, não os valores exatos, de Baratto et al. (2022) para espacialização diária da evapotranspiração de referência (ET₀). Com 12 estações automáticas do INMET no Espírito Santo (2023), comparam-se IDW, ADW, Random Forest, krigagem ordinária e Random Forest Regression Kriging por validação espacial leave-one-out diária. O pipeline inclui limpeza de dados, ET₀ por Hargreaves-Samani, comparação de modelos, Wilcoxon, importância de variáveis, MLflow, Streamlit e Docker. Os resultados mostram desempenho numérico quase equivalente; o RF lidera por pequena margem e o RFRK melhora a suavidade visual dos mapas.

1. Introdução

A evapotranspiração de referência (ET₀) é uma variável meteorológica essencial para balanço hídrico, manejo de irrigação, planejamento agrícola e análise ambiental. Como a rede de estações é espacialmente esparsa, a construção de superfícies contínuas de ET₀ depende de interpoladores capazes de estimar valores em locais sem observação direta.

Baratto et al. (2022) avaliaram IDW, ADW e Random Forest para espacialização de ET₀ diária em bacias da Mata Atlântica. O estudo elegeu RF como melhor interpolador por produzir mapas visualmente mais detalhados, embora as métricas globais fossem muito próximas e o IDW de maior expoente apresentasse desempenho numérico competitivo. A contribuição deste projeto é reproduzir a metodologia em outro recorte, adicionar krigagem ordinária e RFRK, testar significância por Wilcoxon e empacotar o fluxo com práticas de MLOps.

O enquadramento metodológico segue o README atual do projeto: trata-se de uma reprodução de metodologia, não de uma replicação dos números do artigo.

Mudam a rede de estações, o ano, o método de cálculo da ET0 e as covariáveis; o que se avalia é se o padrão de empate técnico entre interpoladores e a discussão RF-versus-IDW se mantêm sob uma implementação aberta e reproduzível.

2. Materiais e métodos

2.1 Dados, ingestão e controle de qualidade

Os dados vêm de estações meteorológicas automáticas do INMET para 2023, filtradas por bounding box no Espírito Santo (longitude -42,0 a -39,5; latitude -21,5 a -17,8). O recorte final contém 12 estações, número próximo às 11 estações convencionais do artigo. Cada CSV contém metadados no cabeçalho (latitude, longitude, altitude, código e UF) e medições horárias no corpo.

A ingestão implementada em `ingest.py` foi desenhada para resistir a variações do layout histórico do INMET. O parser lê arquivos em latin-1, localiza a linha de cabeçalho dos dados, identifica colunas por aproximação textual, converte vírgula decimal, trata valores sentinela (-9999, NULL, vazio) como ausentes e normaliza datas em formatos distintos. Depois, agrega dados horários em Tmax e Tmin diárias. Dias sem amplitude térmica válida são removidos, e estações com menos de 200 dias válidos são descartadas.

Tabela 1. Variáveis e filtros usados na construção da base de ET0.

Componente	Implementação no projeto	Papel técnico
Entrada	CSVs horários do INMET automático	Fonte pública e reproduzível
Metadados	lon, lat, alt do cabeçalho	Covariáveis do RF/RFRK
Temperatura	Tmax e Tmin por agregação diária	Entrada do Hargreaves-Samani
Faltantes	-9999, NULL e vazio para NaN	Evitar contaminação das métricas
Filtro	mínimo de 200 dias válidos	Manter estabilidade temporal por estação

2.2 Cálculo da ET0 por Hargreaves-Samani

A ET0 diária é calculada por Hargreaves-Samani, escolha assumida no README como desvio em relação ao paper. O método é apropriado quando não se deseja depender de vento, umidade e radiação observada. A implementação usa Tmax, Tmin, latitude e dia do ano para estimar a radiação extraterrestre segundo FAO-56.

$$\begin{aligned} ET0 &= 0,0023 * (Tmed + 17,8) * \sqrt{Tmax - Tmin} * (0,408 * Ra), \quad Tmed = \\ &\quad (Tmax + Tmin) / 2 \\ Ra &= (24 * 60 / \pi) * Gsc * dr * [ws * \sin(\phi) * \sin(\delta) + \\ &\quad \cos(\phi) * \cos(\delta) * \sin(ws)] \\ dr &= 1 + 0,033 * \cos(2 * \pi * J / 365); \quad \delta = 0,409 * \sin(2 * \pi * J / 365 - 1,39); \\ ws &= \arccos[-\tan(\phi) * \tan(\delta)] \end{aligned}$$

Nessas expressões, J é o dia do ano, ϕ é a latitude em radianos, $Gsc = 0,0820 \text{ MJ m}^{-2} \text{ min}^{-1}$ é a constante solar e Ra é convertido para lâmina evaporada por 0,408. O resultado é uma matriz Y(data, estação), usada diretamente pelos interpoladores.

2.3 CDD e interpoladores reproduzidos

Antes do ADW, estima-se a CDD (correlation decay distance) uma única vez a partir das séries completas de ET0. Para cada par de estações com sobreposição suficiente, calcula-se a correlação temporal r e a distância x por Haversine, ajustando o modelo $r = \exp(-x/CDD)$. Como não é possível estimar CDD a partir de um único dia, ela é tratada como parâmetro global do conjunto.

$$\text{IDW: } \hat{z}(s_0) = \frac{\sum_i [d(s_0, s_i)^{-p} * z(s_i)]}{\sum_i [d(s_0, s_i)^{-p}]}, \quad p \in \{1, 2, 3, 4, 5\}$$

$$\text{ADW: } w_i = [\exp(-d_i/CDD)]^m, \quad W_i = w_i * (1 + a_i), \quad m = 4, \quad n_{\text{vizinhos}} = 8$$

O IDW representa a família de interpoladores por distância inversa avaliada no artigo. O ADW adiciona um termo angular que valoriza vizinhos distribuídos em direções diferentes, reduzindo o efeito de estações agrupadas em um mesmo setor.

2.4 Modelos adicionados: RF, OK e RFRK

O RF usa longitude, latitude e altitude como atributos. Sua predição é a média das predições de B árvores treinadas sobre amostras bootstrap, com aleatorização interna nas divisões. No projeto, usa-se RandomForestRegressor com 200 árvores no modo normal e 80 no modo fast.

$$\text{RF: } \hat{f}_{\text{RF}}(x) = (1/B) * \sum_{b=1..B} T_b(x), \quad x = [\text{lon}, \text{lat}, \text{alt}]$$

A krigagem ordinária (OK) entra como benchmark geoestatístico ausente no paper. A implementação usa variograma exponencial com patamar igual à variância amostral, alcance igual a um terço da maior distância entre estações e pepita nula. O sistema de krigagem é resolvido por pseudo-inversa, estratégia estável para poucos pontos.

$$\text{Variograma OK: } \gamma(h) = C_0 + C * [1 - \exp(-h/a)], \quad C_0 = 0, \quad C = \text{var}(z), \quad a = \text{max_dist}/3$$

O RFRK combina RF e OK: primeiro ajusta o RF nas covariáveis, calcula resíduos $e_i = z_i - \hat{f}_{\text{RF}}(x_i)$, krige esses resíduos e soma o campo residual à predição do RF. A hipótese é preservar a capacidade não linear do RF e reduzir artefatos em blocos por meio da autocorrelação espacial dos resíduos.

$$\text{RFRK: } \hat{z}_{\text{RFRK}}(s_0) = \hat{f}_{\text{RF}}(x_0) + \hat{e}_{\text{OK}}(s_0), \quad e_i = z_i - \hat{f}_{\text{RF}}(x_i)$$

2.5 Validação espacial e métricas

O protocolo de avaliação segue o artigo: leave-one-out espacial, dia a dia. Para cada data, selecionam-se as estações com ET0 válida; uma estação é retirada, o método é ajustado com as demais e prediz o ponto omitido. O procedimento se repete para todas as estações e para todos os dias com pelo menos cinco estações válidas. Assim, as métricas são calculadas sobre todos os pares observado-estimado acumulados.

$$d = 1 - \frac{\sum_i (E_i - O_i)^2}{\sum_i (|E_i - O_{\text{bar}}| + |O_i - O_{\text{bar}}|)^2}$$

$$\text{RMSE} = \sqrt{\text{mean}_i (E_i - O_i)^2}; \quad \text{BIAS} = \text{mean}_i (O_i - E_i); \quad \text{MAE} = \text{mean}_i |E_i - O_i|$$

A convenção de BIAS segue o paper: $\text{BIAS} = O - E$, de modo que valor negativo indica superestimação. Para avaliar se diferenças pequenas são consistentes ao longo do ano, calcula-se o RMSE diário por método e aplica-se o teste de Wilcoxon pareado do RFRK contra cada outro interpolador.

2.6 MLOps e empacotamento

A solução é executada por CLI e registrada no MLflow. Cada run armazena parâmetros (bbox, ano, número de estações, método de ET0, covariáveis, árvores do RF, CDD e lista de métodos), métricas (`{método}__{métrica}`), p-valores de Wilcoxon, tags e artefatos (`resultados.md`, `tabela3.csv`, `pred_long.parquet` e figuras). O dashboard Streamlit lê o store do MLflow e permite comparar execuções e inspecionar resultados. O Docker Compose define serviços para pipeline, UI do MLflow e dashboard.

3. Resultados e discussão

A execução principal usa 12 estações, 365 dias de 2023, RF com 200 árvores e CDD estimada em aproximadamente 3222 km. O valor elevado de CDD indica que as séries de ET0 no recorte têm forte componente sazonal compartilhado, com baixa queda de correlação na escala espacial do estado.

Tabela 2. Métricas globais por interpolador no protocolo LOO-CV.

Método	d	RMSE	BIAS	MAE
IDW1	0,946	0,567	0,028	0,426
IDW2	0,947	0,565	0,035	0,426
IDW3	0,946	0,573	0,025	0,436
IDW4	0,944	0,584	0,011	0,449
IDW5	0,942	0,593	0,000	0,458
ADW	0,945	0,575	0,021	0,431
RF	0,948	0,564	-0,027	0,419
OK	0,945	0,578	0,008	0,446
RFRK	0,946	0,573	-0,019	0,429

Os resultados mostram empate técnico. O RF lidera d, RMSE e MAE, mas a diferença para IDW1/IDW2 é mínima. Esse resultado conversa diretamente com Baratto et al. (2022): a decisão pelo melhor interpolador não pode ser baseada apenas em diferenças globais muito pequenas; mapas, viés e interpretabilidade precisam entrar na análise.




Figura 1. Índice d de Willmott e RMSE por método. A proximidade das barras evidencia o empate técnico.

3.1 Significância estatística

O Wilcoxon pareado dimensiona se as diferenças diárias são sistemáticas. A leitura central é que significância estatística não implica relevância prática: RF supera RFRK com p-valor muito baixo, mas a mediana da diferença é aproximadamente 0,008 mm/dia, valor operacionalmente irrelevante. Por outro lado, RFRK supera IDW4, IDW5 e OK em RMSE diário, indicando que a krigagem dos resíduos pode ajudar contra métodos mais rígidos.

Tabela 3. Wilcoxon pareado do RFRK contra cada método, usando RMSE diário.

RFRK vs.	Dif. mediana	p-valor	Leitura técnica
RF	+0,008	aprox. 0	RFRK pior, mas diferença prática desprezível
ADW	-0,009	0,995	sem evidência de diferença
IDW1	-0,003	0,038	diferença estatística mínima
IDW2	-0,002	0,037	diferença estatística mínima
IDW3	-0,016	0,386	sem evidência de diferença
IDW4	-0,024	0,0004	RFRK melhor no RMSE diário
IDW5	-0,028	aprox. 0	RFRK melhor no RMSE diário
OK	-0,026	0,002	RFRK melhor que krigagem pura

3.2 Mapas e dispersão observado-estimado

A análise visual é onde o RFRK se diferencia. O RF produz superfícies mais segmentadas, com transições em blocos típicas de árvores de decisão. O RFRK suaviza parte desse comportamento ao modelar resíduos por krigagem. O ganho, portanto, é principalmente cartográfico e interpretativo, não uma melhora numérica ampla.




Figura 2. ET0 interpolada em verão e inverno por IDW2, RF e RFRK. O RFRK suaviza parte dos blocos do RF.

Os gráficos observado-estimado reforçam a proximidade entre RF e RFRK. No inverno, os pontos ficam mais próximos da identidade 1:1; no verão, a dispersão cresce, coerente com maior amplitude de ET0 e maior variabilidade meteorológica.




Figura 3. Dispersão observado-estimado para RF e RFRK em verão e inverno.

3.3 Importância de variáveis

A importância de variáveis foi estimada com um RF auxiliar treinado com dados empilhados de todos os dias, incluindo lon, lat, altitude e dia do ano (doy). O doy domina a explicação do modelo, com importância próxima de 0,87; altitude, longitude e latitude têm pesos menores. Assim, no recorte de 2023, a habilidade do RF parece vir mais da sazonalidade da ET0 do que de estrutura espacial forte.




Figura 4. Importância de variáveis do RF. O dia do ano domina a previsão.

4. Desvios metodológicos assumidos

O README do projeto explicita que o trabalho reproduz a metodologia, não os números exatos do paper. Os desvios são: uso de estações automáticas do INMET em vez das convencionais; ET0 por Hargreaves-Samani em vez de Penman-Monteith; covariáveis restritas a lon, lat e altitude; ADW na forma canônica de New et al.; e OK com variograma exponencial fixo. Essas decisões reduzem dependências externas e tornam o pipeline executável com dados abertos, mas deslocam a comparação para o nível metodológico, e não para a reprodução direta dos valores numéricos originais.

5. Conclusão

O projeto confirma, em uma reprodução metodológica aberta, que interpoladores simples e modelos de aprendizado de máquina podem ficar numericamente muito próximos na espacialização diária da ET0. O RF lidera por margem pequena; IDW1/IDW2 permanecem competitivos; OK funciona como benchmark geoestatístico; e RFRK melhora a leitura visual dos mapas sem dominar as métricas globais. Esse resultado reforça uma leitura importante do artigo-base: quando as diferenças numéricas entre métodos são pequenas, a escolha do interpolador não deve depender apenas de uma métrica agregada, mas também da estabilidade espacial do mapa, do viés, da interpretabilidade e do custo de execução.

A contribuição mais forte está na integração: ingestão defensiva dos dados, cálculo de ET0, LOO espacial, comparação de nove interpoladores, Wilcoxon, importância de variáveis, MLflow, dashboard e Docker. Assim, a entrega não fica restrita à reprodução isolada de uma tabela de resultados: ela organiza um fluxo reprodutível, rastreável e executável de ponta a ponta, aproximando a análise científica de uma solução de Machine Learning operacional. Trabalhos futuros

naturais são implementar Penman-Monteith, incluir DEM e variáveis topográficas, ajustar variogramas por fold e registrar formalmente um modelo final versionado no MLflow.

Referências

- Allen, R. G., Pereira, L. S., Raes, D., and Smith, M. (1998). Crop evapotranspiration: guidelines for computing crop water requirements. FAO Irrigation and Drainage Paper 56, FAO, Rome.
- Baratto, P. F. B., Cecílio, R. A., Teixeira, D. B. S., Zanetti, S. S., and Xavier, A. C. (2022). Random forest for spatialization of daily evapotranspiration (ET₀) in watersheds in the Atlantic Forest. *Environmental Monitoring and Assessment*, 194:449.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5-32.
- Hargreaves, G. H. and Samani, Z. A. (1985). Reference crop evapotranspiration from temperature. *Applied Engineering in Agriculture*, 1(2):96-99.
- Hengl, T., Heuvelink, G. B. M., and Rossiter, D. G. (2007). About regression-kriging: from equations to case studies. *Computers & Geosciences*, 33(10):1301-1315.
- INMET - Instituto Nacional de Meteorologia (2023). Dados históricos das estações automáticas. <https://portal.inmet.gov.br/dadoshistoricos>.
- New, M., Hulme, M., and Jones, P. (2000). Representing twentieth-century space-time climate variability. Part II: development of 1901-96 monthly grids of terrestrial surface climate. *Journal of Climate*, 13(13):2217-2238.
- Pedregosa, F. et al. (2011). Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, 12:2825-2830.
- Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80-83.
- Willmott, C. J. (1981). On the validation of models. *Physical Geography*, 2(2):184-194.