

Espacialização da evapotranspiração de referência (ET_0) diária: reprodução de Baratto et al. (2022) e contribuição com krigagem, RFRK e teste de Wilcoxon

Antonio Albuquerque de Oliveira Neto¹, Gabriel Antônio de Oliveira Rocha¹

¹Recife – PE – Brasil

{aaon, gaor}@cesar.school

Abstract. *This work reproduces the comparison of daily reference-evapotranspiration (ET_0) interpolators by Baratto et al. (2022) — IDW (powers 1–5), ADW and Random Forest (RF) — evaluated by leave-one-out cross-validation (LOO-CV) with Willmott’s d , RMSE, BIAS and MAE, over 12 automatic INMET stations in Espírito Santo, Brazil (2023). We add four elements absent from the original study: ordinary kriging (OK) as a geostatistical benchmark, Random Forest Regression Kriging (RFRK), a paired Wilcoxon test, and an RF variable-importance analysis. The interpolators are nearly indistinguishable (RF leads d /RMSE/MAE by a negligible margin). Wilcoxon shows that the “significant” differences are practically irrelevant (≈ 0.008 mm/day); RFRK removes RF’s blocky artifacts with lower bias; and variable importance reveals that RF’s skill is mostly seasonal (day-of-year ≈ 0.87), not spatial. The pipeline is packaged with CLI, MLflow, a Streamlit dashboard and Docker.*

Resumo. *Este trabalho reproduz a comparação de interpoladores de evapotranspiração de referência (ET_0) diária de Baratto et al. (2022) — IDW (potências 1–5), ADW e Random Forest (RF) — avaliada por validação cruzada leave-one-out (LOO-CV) com o índice d de Willmott, RMSE, BIAS e MAE, sobre 12 estações automáticas do INMET no Espírito Santo (2023). Acrescentam-se quatro elementos ausentes do estudo original: a krigagem ordinária (OK) como benchmark geoestatístico, o Random Forest Regression Kriging (RFRK), um teste de Wilcoxon pareado e a análise de importância de variáveis do RF. Os interpoladores são quase indistinguíveis (o RF lidera d /RMSE/MAE por margem desprezível). O Wilcoxon mostra que as diferenças “significativas” são praticamente irrelevantes ($\approx 0,008$ mm/dia); o RFRK remove os artefatos “em blocos” do RF com menor viés; e a importância de variáveis revela que a habilidade do RF é majoritariamente sazonal (dia do ano $\approx 0,87$), não espacial. O pipeline é empacotado com CLI, MLflow, painel Streamlit e Docker.*

1. Introdução

A evapotranspiração de referência (ET_0) é uma variável central no balanço hídrico e no manejo da irrigação, mas é medida em poucos pontos: a rede de estações meteorológicas é esparsa frente à extensão das bacias hidrográficas. Por isso, *espacializar* a ET_0 — estimar seu valor onde não há estação, a partir das estações vizinhas — é um problema recorrente

em hidrologia e agrometeorologia. A escolha do método de interpolação é o ponto sensível: vai do clássico *Inverse Distance Weighting* (IDW) a métodos geoestatísticos e, mais recentemente, a aprendizado de máquina.

O trabalho de [Baratto et al. 2022] compara, em bacias da Mata Atlântica, interpoladores de ET_0 diária — IDW com expoentes de 1 a 5, o *Angular Distance Weighting* (ADW) e o *Random Forest* (RF) — por validação cruzada *leave-one-out* (LOO), e elege o RF como “melhor” método. Há, porém, uma tensão no próprio resultado: o RF é escolhido pelo *detalhe espacial dos mapas*, embora *não vença nas métricas* — no estudo original, o IDW de expoente alto tem o maior índice d de Willmott. A escolha do “vencedor”, ali, é qualitativa. Além disso, o paper deixa três lacunas: (i) não inclui um *benchmark* geoestatístico (krigagem); (ii) não testa se as diferenças entre métodos são estatisticamente significativas; e (iii) afirma a vantagem do RF mas nunca mostra *de onde* ela vem (quais variáveis o RF de fato usa).

Este trabalho tem dois objetivos. O primeiro é **reproduzir** a metodologia de [Baratto et al. 2022] em outra região e período — estações automáticas do INMET no Espírito Santo, ano de 2023 — verificando se o padrão central se mantém. O segundo é **contribuir** com aquilo que o paper deixou em aberto:

1. **OK** — krigagem ordinária, o *benchmark* geoestatístico ausente no paper;
2. **RFRK** — *Random Forest Regression Kriging* (RF nas covariáveis + krigagem dos resíduos), método híbrido que ataca as duas fraquezas do RF (perder nas métricas e gerar mapas “em blocos”);
3. **teste de significância** (Wilcoxon pareado, dia a dia), que responde ao “a diferença é pequena?” nunca testado no paper;
4. **importância de variáveis** do RF, incluindo o dia do ano, quantificando quanto da habilidade do RF é sazonal *versus* espacial.

Todo o experimento é empacotado para reprodutibilidade com interface de linha de comando (CLI), rastreamento de experimentos com MLflow, painel interativo em Streamlit e contêineres Docker.

2. Materiais e métodos

2.1 Dados

Os dados provêm das **estações meteorológicas automáticas do INMET** [INMET 2023], para o ano de **2023**, recortadas ao **Espírito Santo** por um *bounding box* (longitude $-42,0$ a $-39,5$; latitude $-21,5$ a $-17,8$). O recorte reúne **12 estações** — número próximo das 11 estações convencionais do paper, e na mesma região de Mata Atlântica. Cada arquivo CSV traz, no cabeçalho, os metadados da estação (latitude, longitude, altitude) e, no corpo, medições horárias. A leitura é deliberadamente *defensiva* (o leiaute do INMET muda de ano a ano): localiza colunas por nome aproximado, trata vírgula decimal, códigos de falta (-9999) e múltiplos formatos de data; agrega o horário em diário (T_{max} e T_{min}) e descarta estações com menos de 200 dias válidos. As covariáveis usadas são **longitude**, **latitude** e **altitude** (sem dependência de GIS).

2.2 Cálculo da ET_0 (Hargreaves–Samani)

A ET_0 diária é calculada por **Hargreaves–Samani** [Hargreaves and Samani 1985], que requer apenas temperatura — é o *fallback* recomendado pela FAO-56 quando faltam dados de vento, umidade e radiação [Allen et al. 1998], e é o método do banco BRAUM citado no paper:

$$ET_0 = 0,0023 (T_{med} + 17,8) \sqrt{T_{max} - T_{min}} (0,408 R_a), \quad T_{med} = \frac{T_{max} + T_{min}}{2}, \quad (1)$$

onde R_a é a radiação no topo da atmosfera ($MJ\ m^{-2}\ dia^{-1}$), dada pela formulação FAO-56:

$$R_a = \frac{24 \cdot 60}{\pi} G_{sc} d_r (\omega_s \sin \varphi \sin \delta + \cos \varphi \cos \delta \sin \omega_s), \quad (2)$$

com $G_{sc} = 0,0820$, distância relativa Terra–Sol $d_r = 1 + 0,033 \cos(\frac{2\pi}{365}J)$, declinação solar $\delta = 0,409 \sin(\frac{2\pi}{365}J - 1,39)$, ângulo horário do pôr do sol $\omega_s = \arccos(-\tan \varphi \tan \delta)$, latitude φ e dia do ano J . O resultado é uma tabela ET_0 (datas $\times$ estações) e uma tabela de coordenadas (lon, lat, alt) por estação.

2.3 Interpoladores

Todos os interpoladores compartilham a mesma interface (*fit/predict*); as distâncias usam a fórmula de Haversine.

Reprodução (do paper).

- **IDW1–IDW5** — *Inverse Distance Weighting* com expoente $p \in \{1, \dots, 5\}$: $\hat{z}(x_0) = \sum_i w_i z_i / \sum_i w_i$, com $w_i = d_i^{-p}$. Quanto maior p , mais local a estimativa.
- **ADW** — *Angular Distance Weighting* [New et al. 2000], com 8 vizinhos e $m = 4$. O peso de distância $w_i = [\exp(-x_i/CDD)]^m$ é multiplicado por um termo angular que favorece vizinhos espalhados em direções distintas: $WE_i = w_i (1 + a_i)$, com $a_i = \sum_{l \neq i} w_l (1 - \cos \theta_{il}) / \sum_{l \neq i} w_l$. A CDD (*correlation decay distance*) é estimada uma única vez da série completa, ajustando $r = \exp(-x/CDD)$ sobre os pares de estações.
- **RF** — *Random Forest* [Breiman 2001; Pedregosa et al. 2011] com lon, lat e altitude como atributos, exatamente como no paper.

Contribuição (ausente no paper).

- **OK** — *krigagem ordinária* com variograma exponencial $\gamma(h) = C_0 + C(1 - e^{-h/a})$, patamar C igual à variância amostral, alcance $a = h_{max}/3$ e pepita $C_0 = 0$ (escolha estável para poucas estações); o sistema de krigagem é resolvido por pseudo-inversa com a restrição de não-viés. É o *benchmark* geoestatístico que faltava.
- **RFRK** — *Random Forest Regression Kriging* [Hengl et al. 2007], a contribuição central. Treina-se o RF nas covariáveis, calculam-se os resíduos $r_i = z_i - \hat{z}_{RF}(x_i)$ e *kriga-se* o resíduo com OK; a predição final é

$$\hat{z}_{RFRK}(x_0) = \hat{z}_{RF}(x_0) + \hat{r}_{OK}(x_0). \quad (3)$$

Soma o detalhe do RF à autocorrelação espacial da krigagem, atacando diretamente as duas fraquezas do RF: perder nas métricas e produzir superfícies “em blocos”.

2.4 Protocolo de validação e métricas

Reproduz-se o protocolo *leave-one-out* (LOO) do paper, **dia a dia**: para cada dia, retira-se uma estação por vez, interpola-se o seu valor com as demais e comparam-se observado (O) versus estimado (E); acumulam-se os pares sobre todos os dias e estações (dias com menos de 5 estações válidas são descartados). É uma validação *espacial*. As métricas, no mesmo sentido do paper, são o índice d de Willmott [Willmott 1981], a raiz do erro quadrático médio (RMSE), o viés (BIAS) e o erro absoluto médio (MAE):

$$d = 1 - \frac{\sum_i (E_i - O_i)^2}{\sum_i (|E_i - \bar{O}| + |O_i - \bar{O}|)^2}, \quad \text{BIAS} = \frac{1}{n} \sum_i (O_i - E_i). \quad (4)$$

Por convenção do paper, $\text{BIAS} = O - E$, de modo que *valor negativo indica superestimativa* do método. O índice d varia em $[0, 1]$ (maior é melhor).

2.5 Análises adicionais

Significância (Wilcoxon pareado). Calcula-se o RMSE *de cada dia* por método e aplica-se o teste de Wilcoxon pareado [Wilcoxon 1945] do RFRK contra cada um dos demais. Isso responde, com um p -valor, à pergunta deixada em aberto pelo paper: *a diferença entre métodos é pequena/relevante?*

Importância de variáveis. Treina-se *um* RF empilhando todos os dias, com as variáveis lon, lat, altitude e doy (dia do ano), e mede-se a importância média de cada uma. Incluir o doy permite separar quanto da capacidade preditiva do RF vem do *ciclo sazonal* versus da posição/relevo — exatamente a promessa que o paper fez e nunca mostrou.

2.6 Reprodutibilidade e infraestrutura

O experimento é totalmente automatizado e rastreável: (i) uma **CLI** (`python -m et0spatial`) orquestra todo o pipeline por *flags*; (ii) cada execução vira um *run* no **MLflow**, registrando parâmetros (bbox, ano, nº de estações/dias, método de ET_0 , covariáveis, nº de árvores, CDD), métricas (`{método}__{métrica}`) e os p -valores de Wilcoxon) e artefatos (as figuras e tabelas); (iii) um **painel Streamlit** lê os *runs* e os apresenta; e (iv) tudo roda em **Docker**, com dependências fixadas, em três serviços (pipeline, UI do MLflow e painel). Um *smoke test* verifica, em modo sintético, que as saídas e o *run* do MLflow são gerados.

3. Resultados e discussão

A configuração avaliada usou as 12 estações do Espírito Santo, os 365 dias de 2023, RF com 200 árvores e CDD estimada em ≈ 3222 km. Esse valor altíssimo de CDD já é informativo: reflete que a ET_0 é dominada por um ciclo sazonal comum a todas as estações, de modo que a correlação quase não decai com a distância na escala do estado.

3.1 Comparação geral: os métodos são quase indistinguíveis

A Tabela 1 traz as métricas LOO-CV por método; a Figura 1 as ilustra. O RF lidera em d , RMSE e MAE, mas por margem mínima: RF ($d = 0,948$), IDW2 (0,947) e IDW1 (0,946) são praticamente indistinguíveis. Recupera-se, assim, o achado central do paper — **os métodos são muito próximos e o IDW simples é competitivo com o RF**. Uma diferença em relação ao estudo original: aqui o melhor IDW é o de expoente *baixo* (IDW1/IDW2),

enquanto no paper foi o de expoente alto; isso depende da densidade de estações e da suavidade do campo. Quanto ao viés, RF e RFRK superestimam levemente ($\text{BIAS} < 0$) e os IDW subestimam ($\text{BIAS} > 0$).

Tabela 1. Métricas por método (LOO-CV, Espírito Santo, 2023). Melhores valores em negrito; d adimensional, RMSE/BIAS/MAE em mm dia^{-1} .

Método	d	RMSE	BIAS	MAE
IDW1	0,946	0,567	0,028	0,426
IDW2	0,947	0,565	0,035	0,426
IDW3	0,946	0,573	0,025	0,436
IDW4	0,944	0,584	0,011	0,449
IDW5	0,942	0,593	0,000	0,458
ADW	0,945	0,575	0,021	0,431
RF	0,948	0,564	−0,027	0,419
OK	0,945	0,578	0,008	0,446
RFRK	0,946	0,573	−0,019	0,429




Figura 1. Índice d de Willmott (esq.) e RMSE (dir.) por método. As barras são visualmente quase iguais — a evidência gráfica de que os interpoladores empatam.

3.2 A significância das diferenças (Wilcoxon)

A Tabela 2 compara o RFRK contra cada método pelo RMSE diário. O RFRK é *significativamente melhor* que a krigagem pura (OK) e que os IDW de expoente alto (IDW4, IDW5), *empata* com ADW e IDW3, e é *significativamente pior* que o RF — porém por apenas **0,008 mm/dia** de mediana. Esse é exatamente o ponto que o paper deixou em aberto: com milhares de comparações diárias, diferenças minúsculas tornam-se “significativas”. Em outras palavras, **significância estatística não é o mesmo que relevância prática**.

Tabela 2. Wilcoxon pareado: RFRK versus cada método (RMSE diário). Diferença mediana = med(RFRK) – med(outro); negativo $\Rightarrow$ RFRK melhor. Significativo se $p < 0,05$.

RFRK vs.	Dif. mediana (mm/dia)	p -valor	Significativo
RF	+0,008	≈ 0 (10^{-20})	sim (RFRK pior)
ADW	–0,009	0,995	não
IDW1	–0,003	0,038	sim
IDW2	–0,002	0,037	sim
IDW3	–0,016	0,386	não
IDW4	–0,024	0,0004	sim
IDW5	–0,028	≈ 0 (10^{-7})	sim
OK	–0,026	0,002	sim

3.3 Mapas: os blocos do RF versus a suavidade do RFRK

A Figura 2 mostra a ET_0 interpolada num dia de verão e num de inverno, por IDW2, RF e RFRK. O RF produz uma superfície *em degraus* (“blocos”), artefato natural das árvores de decisão; o RFRK, ao reintroduzir a estrutura espacial via krigagem dos resíduos, entrega um mapa visivelmente mais suave. Embora não vença nas métricas, o RFRK tem *menor viés* (BIAS –0,019 contra –0,027 do RF). O ganho do RFRK é, portanto, qualitativo (corrige o artefato em blocos) mais do que numérico.




Figura 2. ET_0 interpolada (mm/dia) em verão (linha superior) e inverno (inferior) por IDW2, RF e RFRK. Note os “blocos” do RF, em degraus, contra a suavidade do RFRK; pontos pretos são as estações.

3.4 A habilidade do RF é sazonal, não espacial

O resultado mais nítido é a importância de variáveis (Figura 3): o **dia do ano responde por $\approx 87\%$** da capacidade preditiva do RF, ao passo que tudo o que é espacial (lon + lat + altitude) soma apenas $\approx 13\%$ (doy 0,867; alt 0,078; lon 0,031; lat 0,024). Isso recontextualiza o “detalhe espacial” celebrado no paper: a força do RF vem majoritariamente de capturar o *ciclo sazonal* da ET_0 , não a estrutura espacial. E explica por que o RFRK *não* melhora as métricas — como o resíduo do RF tem pouca estrutura espacial a explorar, a krigagem dos resíduos tem pouco do que tirar proveito.




Figura 3. Importância de variáveis do RF (com o dia do ano, doy). O doy domina; lon, lat e altitude têm peso marginal.

A Figura 4 reforça o ponto pelo lado sazonal: a dispersão observado $\times$ estimado é melhor no inverno ($d \approx 0,89$) do que no verão ($d \approx 0,84$), e o RF e o RFRK são praticamente sobreponíveis em ambas as estações — coerente com o achado de que sobra pouca estrutura espacial nos resíduos.




Figura 4. Observado $\times$ estimado para RF e RFRK, em verão e inverno. A linha tracejada é a identidade 1:1; os rótulos trazem d e RMSE por estação do ano.

4. Conclusão e trabalhos futuros

A reprodução recupera o padrão de [Baratto et al. 2022]: os interpoladores ficam muito próximos e o IDW simples compete de igual para igual com o RF, que lidera por margem desprezível. A contribuição acrescenta o rigor que faltava para discutir isso: o **Wilcoxon** mostra que as diferenças, quando significativas, são minúsculas; o **OK** dá o *benchmark* geoestatístico; o **RFRK** corrige o artefato “em blocos” do RF (com menor viés), ainda que sem ganho de métrica; e a **importância de variáveis** revela que a habilidade do RF é, sobretudo, *sazonal*. A lição metodológica é que a escolha do “melhor” interpolador, neste problema, não se decide pelas métricas globais — elas empatam — e sim por critérios práticos (suavidade do mapa, viés, custo).

Limitações e desvios assumidos (reprodução de *metodologia*, não dos números exatos): estações *automáticas* do INMET (não as 11 convencionais), outra região e período; ET_0 por Hargreaves–Samani (não Penman–Monteith); covariáveis reduzidas a lon/lat/altitude (sem declividade/aspecto/distância ao mar); ADW na forma canônica de New et al. ($WE = w(1 + a)$), enquanto o paper escreve $1 - a$); e OK com variograma exponencial fixo. **Trabalhos futuros**: ajuste de variograma por *fold*, inclusão de covariáveis topográficas (DEM), ET_0 por Penman–Monteith e a inclusão explícita da sazonalidade nos interpoladores espaciais.

Referências

- Allen, R. G., Pereira, L. S., Raes, D., and Smith, M. (1998). *Crop evapotranspiration: guidelines for computing crop water requirements*. FAO Irrigation and Drainage Paper 56, FAO, Rome.
- Baratto, J., Wollmann, C. A., Iensse, A. C., and Roberti, D. R. (2022). “Random forest for spatialization of daily evapotranspiration (ET_0) in watersheds in the Atlantic Forest”.

- Environmental Monitoring and Assessment*, 194:449.
- Breiman, L. (2001). “Random forests”. *Machine Learning*, 45(1):5–32.
- Hargreaves, G. H. and Samani, Z. A. (1985). “Reference crop evapotranspiration from temperature”. *Applied Engineering in Agriculture*, 1(2):96–99.
- Hengl, T., Heuvelink, G. B. M., and Rossiter, D. G. (2007). “About regression-kriging: from equations to case studies”. *Computers & Geosciences*, 33(10):1301–1315.
- INMET — Instituto Nacional de Meteorologia (2023). *Dados históricos das estações automáticas*. <https://portal.inmet.gov.br/dadoshistoricos>.
- New, M., Hulme, M., and Jones, P. (2000). “Representing twentieth-century space–time climate variability. Part II: development of 1901–96 monthly grids of terrestrial surface climate”. *Journal of Climate*, 13(13):2217–2238.
- Pedregosa, F. et al. (2011). “Scikit-learn: machine learning in Python”. *Journal of Machine Learning Research*, 12:2825–2830.
- Wilcoxon, F. (1945). “Individual comparisons by ranking methods”. *Biometrics Bulletin*, 1(6):80–83.
- Willmott, C. J. (1981). “On the validation of models”. *Physical Geography*, 2(2):184–194.